- **Nama Mahasiswa:** M Reza Maulani Aditya
- **NIM:** 2410010638
- **Kelas:** Non Reguler Banjarmasin (Teknik Informatika)
- **Mata Kuliah:** Machine Learning (Pertemuan 3)

A. Pendahuluan

Praktikum ini bertujuan untuk memahami dan menerapkan tahapan *Data Preparation* (penyiapan data) sebagai fondasi utama sebelum melatih model *Machine Learning*. Data yang digunakan adalah dataset **Spotify Artist Streaming (2020–2025)** yang berisi informasi trek lagu, popularitas, fitur audio, dan jumlah *stream*.

B. Tahapan Pengerjaan dan Kode

1. Memuat Dataset dan Inspeksi Awal

Tahap pertama adalah memuat file CSV ke dalam lingkungan Python menggunakan pustaka pandas dan melihat beberapa baris pertama data.

Python:

```
import pandas as pd

from sklearn.preprocessing import MinMaxScaler

# Memuat dataset

df = pd.read_csv("spotify_artist_streaming_2020_2025.csv")

# Cek 5 baris pertama

df.head()
```

2. Eksplorasi Data (EDA)

Melakukan pengecekan struktur data, tipe data, statistik deskriptif, dan mendeteksi apakah ada nilai yang kosong (*missing values*).

Python:

```
# Informasi struktur data

df.info()

# Statistik ringkas data numerik

df.describe()

# Cek data kosong

df.isnull().sum()
```

3. Pembersihan Data (Data Cleaning)

Membersihkan data kosong dengan mengisi nilai median untuk kolom numerik, modus untuk kolom kategorikal, serta menghapus baris data yang duplikat.

Python:

```
# Mengisi data kosong numerik dengan median
for col in df.select_dtypes(include=['number']).columns:
    df[col].fillna(df[col].median(), inplace=True)
# Mengisi data kosong kategorikal dengan modus
for col in df.select_dtypes(include=['object']).columns:
    df[col].fillna(df[col].mode()[0], inplace=True)
# Hapus duplikat
df.drop_duplicates(inplace=True)
```

4. Encoding Data Kategorikal

Mengubah kolom kategori (seperti genre) menjadi bentuk numerik agar dapat diproses oleh algoritma *Machine Learning* menggunakan *One-Hot Encoding*.

Python:

```
if 'genre' in df.columns:
    df = pd.get_dummies(df, columns=["genre"], drop_first=True)
```

5. Normalisasi Data Numerik

Menyamakan skala nilai fitur numerik (seperti danceability, energy, tempo) ke dalam rentang 0 sampai 1 agar tidak ada kolom yang mendominasi model.

Python:

```
scaler = MinMaxScaler()
num_cols = ['danceability', 'energy', 'tempo', 'duration_ms', 'popularity']
df[num_cols] = scaler.fit_transform(df[num_cols])
```

6. Rekayasa Fitur (Feature Engineering)

Membuat kolom atau fitur baru yang lebih bermakna untuk membantu model mengenali pola. Pada laporan ini, dibuat fitur streams_per_minute (rasio jumlah *stream* terhadap durasi lagu).

Python:

```
df['streams_per_minute'] = df['stream_count'] / (df['duration_minutes'] + 1)
```

7. Pemisahan Fitur (X) dan Target (y)

Memisahkan variabel masukan/fitur (X) dengan kolom target yang ingin diprediksi (y, yaitu stream_count).

Python:

```
X = df.drop(columns=['track_id', 'track_name', 'artist_name', 'album_name', 'release_date', 'stream_count'], errors='ignore')

y = df['stream_count']
```

C. Analisis Jebakan Data (*Data Traps*)

Berdasarkan eksplorasi pada dataset Spotify ini, beberapa potensi jebakan data (*data traps*) yang perlu diwaspadai meliputi:

1. **Data Leakage (Kebocoran Data):** Memasukkan kolom yang secara langsung merepresentasikan target masa depan (misalnya kolom metrik hasil turunan langsung dari target) yang dapat membuat akurasi model menjadi tidak realistis saat diuji di dunia nyata.
2. **Dummy Variable Trap:** Redundansi kolom hasil *one-hot encoding* yang dapat diatasi menggunakan parameter drop_first=True.

D. Kesimpulan

Penyiapan data (*data preparation*) memegang peranan krusial hingga 80% dalam keberhasilan proyek *Machine Learning*. Melalui praktikum ini, data mentah Spotify berhasil dibersihkan, dinormalisasi, dan direkayasa sehingga siap digunakan untuk tahap pemodelan selanjutnya.